
上海交通大学

SHANGHAI JIAO TONG UNIVERSITY

学士学位论文

THESIS OF BACHELOR



论文题目：基于眼底视网膜图像的渗出物自动检测

学生姓名：冯忠伟

学生学号：5110309425

专 业：信息工程

指导教师：杨宇红

学院(系)：电子信息与电气工程学院

基于眼底视网膜图像的渗出物自动检测

摘要

糖尿病视网膜病变是一种严重的眼科疾病，是成年人致盲的重要原因。人工手动筛查眼底图像需要耗费大量时间，而且准确度低、重复性差，因此计算机自动检测是提高眼底图像检测效率的重要工具。本文实现了渗出物检测的三大类算法，分别是基于阈值分割，基于形态学分割以及基于机器学习的算法，并对其性能进行比较。基于阈值分割的算法是最简单，而且使用很广泛的算法，然而由于眼科摄像光照不均衡，导致图像亮度对比度在各区域不相同，因此选择合适的阈值并不容易，算法检测结果不是很好。综合重建滤波器和暗特征的是基于形态学分割的算法，主要利用渗出物的灰度信息和亮度信息，不考虑其他特征，很容易受到噪声干扰，不能区分具有类似灰度亮度特征的非渗出物干扰，但其运算效率高，耗时短，检测结果较前一种算法有所改进。结合 CIELab 空间和 K 均值聚类的是基于机器学习的算法，是利用亮度信息、颜色信息和对比度等特征区分渗出物和非渗出物的，同时通过优化初始聚类中心的选择，设置合理的聚类数目，选用恰当的视盘检测算法等改进措施，使得其检测结果一般优于其他算法。对眼底图像的亮度通道 I 利用中值滤波去除噪声，利用限制对比度自适应直方图均衡化提高对比度进行图像增强，然后利用渗出物亮黄色的颜色特征对 CIELab 色彩空间的亮度通道运用 K 均值聚类，最后剔除视盘就获得渗出物候选区域。

关键词：眼底图像，渗出物，阈值分割，形态学，K 均值聚类

AUTOMATIC EXUDATE DETECTION IN COLOR RETINAL IMAGE

ABSTRACT

Diabetic Retinopathy is a severe eye disease, which is a leading cause of blindness in adults. Identification of diabetic retinopathy by hands with low accuracy and repeatability, which takes a lot of time. An automatically computerized approach can serve as a important tool to improve the efficiency of assessment of fundus images. In this paper, three algorithms of the detection of exudates are realized, which are based on the threshold segmentation, the morphology segmentation and the machine learning algorithm. The algorithm Based on threshold segmentation is the simplest, which is widely used. Due to the uneven illumination in the Department of Ophthalmology, the brightness and contrast of the images are different in different regions, so it is not easy to choose the appropriate threshold. The algorithm, which take advantage of reconstruction filter and dark features, is based on morphological segmentation. It only utilize gray and intensity information, rather than other characteristics. So it can be disturbed by noise easily, so that we can't distinguish non exudates interference with similar gray and intensity. However, it costs less time with high computational efficiency. The algorithm Integrated CIELab color space and k-means clustering is based on machine learning, which is superior to the others. Through the characteristics of brightness, color and contrast, we can distinguish exudates with non exudates. We use median filter to the channel I from HSI space to remove noise and contrast limited adaptive histogram equalization to enhance the contrast of images, then use k-means clustering to color channels, which is extracted from CIELab color space, finally the optic disc is subtracted from exudate candidate regions.

Key words: fundus images, exudates, threshold segmentation, morphological, k-means clustering

目 录

摘要.....	1
ABSTRACT.....	2
第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	1
1.3 本文研究内容.....	3
1.4 结构安排.....	3
第二章 视网膜图像研究基础.....	4
2.1 视网膜生理结构介绍.....	4
2.2 眼底图像的获取与分类.....	5
2.3 眼底图像视场提取及色彩空间.....	6
2.3.1 视场提取.....	6
2.3.2 颜色空间及转换.....	8
2.4 阈值分割.....	11
2.4.1 阈值分割简介.....	11
2.4.2 阈值分割原理.....	11
2.5 数学形态学处理.....	12
2.5.1 数学形态学简介.....	12
2.5.2 本文使用的形态学运算.....	12
2.6 K 均值聚类.....	13
2.7 本章小结.....	14
第三章 渗出物检测算法研究.....	15
3.1 基于 SVM 的眼底图像渗出物检测.....	15
3.1.1 SVM 简介.....	15
3.1.2 SVM 核函数.....	15
3.1.3 霍夫变换.....	15
3.1.4 算法流程与结果.....	15
3.2 融合重建滤波器和暗特征的渗出物检测.....	18
3.2.1 Top-hat 变换.....	18
3.2.2 限制对比度直方图均衡化.....	19
3.2.3 算法流程与结果.....	19
3.3 本章小结.....	21
第四章 改进 K 均值聚类检测算法.....	22
4.1 改进思路的产生.....	22
4.2 算法的改进点.....	24
4.2.1 初始聚类中心的选择.....	24
4.2.2 聚类数目 k 的确定.....	25
4.2.3 视盘检测.....	27

4.3 改进后的算法流程与结果.....	28
4.4 本章小结.....	30
第五章 实验结果.....	31
5.1 DIARETDB1 图像库介绍.....	31
5.2 分割结果.....	31
5.3 性能比较.....	33
5.4 本章小结.....	34
第六章 结论.....	35
6.1 总结.....	35
6.2 下一步工作.....	35
参考文献.....	36
谢辞.....	38

第一章 绪论

1.1 研究背景与意义

糖尿病正在全世界范围内越来越流行，而糖尿病视网膜病变(diabetic retinopathy, DR)是糖尿病引起的强烈并发症。微血管瘤(Microaneurysms, Ma)是糖尿病视网膜病变的早期特征之一,是由于毛细血管膨胀造成的,表现为视网膜上红色或暗红色圆或椭圆形斑点；微血管瘤的破裂就会导致视网膜出血(hemorrhages, H)，一般发生在病例晚期；视网膜上亮黄色的损伤是硬性渗出物(hard exudates, HEs) 是糖尿病视网膜病变具有特征性的所见之一，是因为血管通透性增加，导致类脂质从血清中渗出，堆积形成，主要表现为大小不等，边缘较为清楚的斑点状。硬性渗出物可能无规则地分布于眼底，但后极部最常见，多个呈簇状堆积，有部分相互融合成片，有部分排列成环状。另外亮白色的损伤是棉绒斑,也叫软性渗出物(soft exudates)，大多分布于动脉的分叉处，既可以在视网膜血管的后面，也可以覆盖视网膜血管。但是它并非糖尿病视网膜病变的特异性改变，高血压病患者眼底也较多见。

研究表明，糖尿病视网膜病变是成年人最主要的致盲原因，而渗出物则是其早期重要的标志之一，因此它也是病变分期和诊断的重要依据。基于数字眼底图像的渗出物检测技术能有效地改善当前的医疗环境，从而有助于开展广泛的眼科普查，同时还能节省患者的诊断成本和治疗费用。

1.2 国内外研究现状

目前国内外有许多渗出物自动检测的算法，主要可以分为基于阈值分割、基于形态学运算、基于机器学习三大类。这些算法各有各的优缺点，并且在检测渗出物方面都取得了一定的效果，但其中很多算法都忽略了眼底图像可能存在的各种各样的干扰因素^[1]。

阈值分割法是一类常见的提取方法，通常是依据渗出物颜色信息，亮度信息以及边缘强度等特征入手的。如 Diptoneel 等提出的一种基于颜色信息和边缘强度的动态阈值渗出物检测算法。

数学形态学法是另一类常见的提取方法，它主要通过形态学运算的方法来实现视网膜背景信息去除，以达到增强血管的目的；或者对已知结构进行处理，改变成需要的形态，如膨胀、腐蚀等。数学形态法一般需要与其他分割方法进行配合，才能发挥出更好的处理效果。

基于机器学习的方法分为两个部分：监督法和非监督法。监督法利用一些预先标记信息进行血管像素的分辨；而非监督法则不需要使用到任何预先标记的信息。如 Osareh 等人提出的一种监督法，事先设计好基于机器学习的分类器，然后分类测试样本和未知像素。这类方法所具有的缺点是相关联的区域大尺度的信息必须在连通区域分割完成以后才能得到，无法直接引导底层算法的区域分割。

高玮玮等^[2]提出一种基于阈值分割和径向基函数(Radial Basis Function, RBF)神经网络的硬性渗出自动检测方法。首先，利用基于最小类内离散度的改进 Otsu 分割方法^[3]对眼底图像绿色通道进行粗分割获取病灶候选区域；接着，通过传统 Otsu 结合形态学操作对眼底图像红色通道进行操作来剔除视盘这个假阳性区域，从而减小后期计算量；然后，利用 logistic 回归对候选区域的多个特征进行选择,最后，把优化后的候选区域特征集及其相应分

类标签作为输入量来训练 RBF 神经网络。因为神经网络训练过程中采用十倍交叉验证,所以该神经网络具有较好的泛化能力。因为需要训练神经网络,此法需要较多时间,但能够保证较高的检测精度。林蔚^[4]提出利用基于 K 近邻图的区域合并算法实现眼底图像中 EXs 的自动检测。首先通过对原图进行图像增强,以增加渗出物与背景的对照度,接着进行边缘检测,可得到边界图。第二步,对原始图像进行血管分割,通过计算所得结果来寻找血管收敛度最大的区域,此为视盘中心。第三步,使用基于 K 近邻图对区域进行合并然后对图像进行分割,初始化分割区域由许多小区域组成,依照该论文中提出的区域相似度概念,对当前区域里面最相似的两个区域进行合并,同时更新区域相似度参数,直到最大的区域相似度参数小于一预先设置的阈值,就停止合并过程。最后根据第二步中所得到的视盘位置,剔除视盘这个假阳性区域,从而可以根据位置信息和颜色特征提取出硬性渗出区域。该方法的优点在于算法的高效性和稳定性,可较快的检测出各种形态的硬性渗出。潘燕红等^[5]先通过形态学结合阈值分割得到候选区域,通过候选区域提取特征,最后通过支持向量机(Support Vector Machine, SVM)分类。首先对眼底灰度图像进行数学形态学开运算结合阈值方法得到候选区域掩膜(Mask),通过霍夫圆变换来进行定位视盘^[6],从 mask 剔除视盘得到硬性渗出的候选区域;然后在候选区域上提取特征向量,并在特征提取中引入调幅-调频(AM-FM)特征,使得检测结果不受眼底图像光照条件和对比度的影响,具有更好适应性;接着用 SVM 分类出 HEs 和非 HEs。此法需要训练 SVM,因此需要较多时间,但有较高精确率。高玮玮等^[7]首先利用数学形态学方法和阈值分割快速提取出视盘,然后通过此基础上得到病灶候选区域,最后利用形态学重建等获取精确的病灶轮廓。首先利用传统 Ostu 对眼底图像红色通道进行阈值分割得到 P1,通过对 P1 进行二值形态学开运算得到 P2,P2 中面积大亮度高的区域即为视盘。接着对眼底图像绿色通道进行灰度形态学闭操作,同时计算每个像素局部方差得到 I1,提取 I1 大于灰度阈值 t1 的区域进行形态学膨胀运算得到 I2,对 I2 的区域边缘腐蚀重建得到 I3,从 I3 中剔除视盘得到候选区域。最后对眼底图像绿色通道加上候选区域的零值进行膨胀重建,与原始绿色通道对比即可得到渗出物。赖小波等^[8]提出利用重建滤波器结合眼底图像暗特征的渗出物检测算法。首先对眼底灰度图像进行滤波器移除眼底血管,接下来对移除血管的灰度图像利用列滤波器提取渗出物,同时通过阈值分割得到含有视盘和边界的渗出物区域。然后从灰度图像中构建视盘掩膜和提取图像边界信息,从含有视盘和边界的渗出物区域中移除视盘和边界信息,从重建滤波后的已扩充尺寸的灰度图像中移除通过 Top-hat 提取的暗特征即得到最终渗出物图像。此算法能有效检测视网膜眼底图像中的渗出物,较现有算法具有更高的检测精度,同时运算效率很高。郑绍华等^[9]提出一种应用方向局部对比度滤波结合局部血管密度的方法。利用 HSV 色彩空间亮度通道 I_v 来消除背景,利用图像尺寸 1/30 大小的中值滤波结果 I_{vmedbg} 作为形态学重建的标记图像,模糊后 I_v 作为模板图像,得到重建背景 I_{vbgrec} 减去背景就得到候选区域 HEs。然后利用 8 方向的柯西算子检测绿色通道边缘得到 I_{gedge} ,对绿色通道进行形态学重建得到 I_{grec} 。同样对边缘进行形态学重建得到 $I_{gedgerec}$ 。 I_{grec} 减去 $I_{gedgerec}$ 就得到渗出物边缘。Youssef 等^[10]通过岁眼底图像进行阈值分割得到包含视盘和少量血管的粗糙图像,然后从粗糙图像中减去血管和通过霍夫变换提取到的视盘就能获得渗出物,最后对渗出物进行重建增强。Reza 等^[11]提出了改进的分水岭分割算法,此法能够从眼底图像中提取渗出物和视盘等主要特征。Sinthanayothin 等利用多层感知神经网络实现黄斑检测、视盘提取以及血管分割^[12]后,通过区域生长完成渗出物的检测^[13]。Rajput 等^[14]通过 K 均值聚类结合分类器检测渗出物区域。首先通过 K 均值聚类初步分离出视网膜渗出物和非渗出物,利用霍夫圆变换剔除视盘这一非阳性区域,然后利用边缘强度和阈值来进行分类。Sopharak 等^[15]首先通过模糊 C 均值聚类(fuzzy c-means clustering, FCM)获得含有渗出物的标记图像,然后对标记图像采用形态学方法进行处理,获得渗出物区域。Gardner 等^[16]利用反相神经网络检测病变图像中的渗出物。Osareh 等^[17,18]人首先利用蛇形拟合分割出视盘,然后分别利

用支持向量机、BP 神经网络完成了渗出物的分割与提取。

1.3 本文研究内容

本文通过阅读国内外大量的参考资料，详细分析理解多种渗出物检测算法，并使用 matlab 实现相关算法，在比较各种算法优缺点的基础上，提出相应的改进方法。对视网膜渗出物检测的整个处理过程进行研究与分析，主要研究内容为：首先对眼底图像渗出物检测的基础知识进行学习研究，如视网膜生理结构、眼底图像色彩空间、视场掩模提取和数字形态学处理等；然后对各种渗出物检测算法进行原理学习与性能分析，掌握其使用特点；之后通过研究各种算法的一些重要问题，改进渗出物检测方法，进行一系列的对比实验，从定性、定量等不同方面证明改进算法所具有的实用性以及有效性。

1.4 结构安排

本文共有六章，各章的内容和安排如下：

第一章 介绍眼底图像渗出物检测领域的研究背景、意义和国内外的研究现状，并对本文的工作内容及结构安排做出简要阐述。

第二章 综述眼底渗出物检测的各类基础知识，包括视网膜的生理结构、眼底图像色彩空间、视场掩模提取以及数学形态学处理等内容，概括性地对这些内容进行理论叙述与方法介绍。

第三章 简单介绍各种算法的原理及流程，并使用 matlab 实现各种算法，比较各种算法的性能和特点，为下一章改进算法打下基础。

第四章 在第三章各种方法的基础上，改进基于 k 均值聚类的眼底视网膜渗出物检测方法。本章主要从算法思想产生、一些问题讨论等几个方面进行说明和讨论，形成一个检测效果较好的算法。

第五章 对算法进行定性、定量的科学评估，通过处理图像对比、表格数据对照的形式展现本文提出的算法的各项性能。

第六章 总结本文的工作、成果和不足之处，并对未来工作做出展望。

第二章 视网膜图像研究基础

2.1 视网膜生理结构介绍

要进行眼底视网膜渗出物的检测和提取，首先应当要了解视网膜的生理结构。因为在视网膜渗出物检测和提取的过程中，需要处理各种各样复杂的结构。在很多情况下，能否正确处理这些非渗出物结构，对眼底视网膜渗出物检测的性能甚至成败有着相当重大的意义。

视网膜是人体眼球后部的一层非常薄的细胞层，形状为一个凹形的球面。因脉络膜和色素上皮细胞的关系，使眼底呈均匀的橘红色^[19]。物体发来的光线经过眼的折光系统，一般会在视网膜上形成像（否则将形成近视或远视），被感光细胞感到。视网膜中分布着许多可以感受光的视杆细胞和视锥细胞，这些细胞可以将他们感受到的光信号转化为神经信号。通过图 2-1 展示的视网膜生理结构图可以分辨出视网膜上的不同结构^[20]：

（1）视网膜中心血管系统：视网膜血管是脑血管的一个分支，主要作用是给视网膜提供必需的营养，视网膜血管形态可以通过眼底检查观察。视网膜上的中央动脉，在眼底至视盘可以分为上下支，在视网膜鼻侧和颞侧上下又一分二，变为四支小动脉，依次类推直到形成毛细血管网。

（2）视盘：视网膜鼻侧附近有一淡红色区即视盘，也称为视神经乳头。其大小由巩膜后部直径的大小和视神经进入眼球的角度共同决定。视盘中央存在生理凹陷，无感光细胞，视野上呈现为固有的暗区，称为生理盲点。

（3）黄斑区：位于眼球后极部、视盘外侧，是视网膜上视觉最敏锐的特殊区域，直径约 1-3mm，一般呈椭圆或近似圆形，颜色表现为红色。

（4）中心凹：是黄斑区中央的小凹，一个直径约 0.1 mm。中心凹处无血管只有视锥细胞，因此视力非常敏锐，可呈现光反射点。




图 2-1 视网膜生理结构

疾病会导致视网膜图像发生改变，产生一些无法预知的干扰结构，对视网膜渗出物检测和提取造成一定程度的干扰。譬如，糖尿病视网膜病变不同时期会产生不同表现形式的病灶。轻度期会有少量出血点和微动脉瘤；中度期则表现出棉絮斑和微血管异常；重度期则会产生静脉串珠样改变、视网膜局部毛细血管无灌注区累及多个象限。另外还有增殖型、黄斑水肿等多种其他形态。图 2-2 为糖尿病患者的眼底视网膜图像。



图 2-2 糖尿病患者眼底视网膜图像

2.2 眼底图像的获取与分类

视网膜眼底图像一般可以通过眼科摄像获得，主要有彩色眼底照相、眼底荧光素血管造影两大类，如图 2-3 所示。眼底荧光素血管造影由于需要静脉注射造影剂，而且造影过程耗时并且存在过敏反应，因此彩色眼底照相技术在视网膜病变检查中广泛运用。彩色眼底照相相对眼底荧光素血管造影较方便和快捷，同时可保证较高准确率，有利于采用信息技术进行自动处理和诊断。



(a) 视网膜荧光造影图像



(b) 彩色视网膜图像

图 2-3 不同类型的眼底图像

但是视网膜荧光造影图像的获取是有创的,而且价格较为昂贵,不适合大规模常规采用。相比之下,彩色视网膜图像尽管对比度相对较差,但是可通过临床上广泛使用的眼底照相机直接获取,较方便和快捷,有利于大规模的眼底图像采集,从而辅助各种疾病的诊断治疗。另外,几个公共的眼底视网膜图像库: DIAREDB1, STARE 和 DRIVE 提供的都是彩色视网膜图像,因此本文选择彩色视网膜图像作为对象进行处理。


通过研究发现,彩色眼底视网膜图像采集过程中常受到许多非理想成像条件的限制,例如光照不均匀或反射、折射、散射等因素的影响,使图像表现出亮度不均、色彩变化、反差过强及血管对比度弱等特点,这也成为了视网膜渗出物的检测和提取的难点所在。因此,为了改善原有图像的质量,必须增强需要的图像特征信息,抑制干扰因素,使渗出物检测和提取能够在较为理想的条件下进行,有必要对彩色视网膜原始图像进行一系列的预处理。

2.3 眼底图像视场提取及色彩空间

2.3.1 视场提取

对于眼底图像,由于成像镜头的因素,拍摄出来之后,眼底图像的周围总会存在一部分暗色的所谓背景,然而眼底视网膜的组织信息只存在于中央圆形区域。为了方便后续处理,消除不必要信息干扰,首先就要去除周围背景区域。有的图像库,如 DIAREDB1 和 DRIVE 会自带掩模帮助去除暗色区域,但如 STARE 图像库就没有提供掩模,于是提出提取图像掩模的方法。通常做法是利用原始眼图生成一个掩模图像,来屏蔽不关心的部分。此掩模图像包含有眼底图像的信息分布,一般称为“视场”。本文采用基于 HSV 空间亮度信息的分割方法^[21]提取视场。

处理过程中所使用的模型不是常见的 RGB 模型,而是 HSV 色彩模型。HSV 模型是从 CIE 三维色彩空间演变而来,由表示色相的 H (Hue),表示饱和度的 S (Saturation),表示色调的 V (Value) 组成。色相表示从物体反射或透过物体传播的色彩,也就是平常认知上的颜色概念,它可以通过 0~360° 标准色轮上的位置进行度量。饱和度是指颜色的强度或纯度,由小到大可用 0% (灰色) 到 100% (完全饱和) 的百分比来表示。颜色的相对明暗程度可用色调来表示,度量大小从 0% (黑色) 至 100% (白色)。图 2-4 展示了一幅彩色视网膜图像的 HSV 分量灰度图。



(a) H 分量灰度图

(b) S 分量灰度图

(c) V 分量灰度图

图 2-4 HSV 色彩空间分量灰度图

HSV 颜色模型有两个特点:

- (1) V 分量不包含任何眼底图像的色彩信息;
- (2) H 和 S 分量与颜色信息紧密相连的。

由于 HSV 模型的这些特点, 其非常适合用来研究基于彩色特征的图像处理算法。因为 RGB 彩色眼底图像可以直接提供 R、G、B 三个通道的信息, 因此可以采取一定的转换公式来帮助完成提取过程。

先获取彩色视网膜图像的 R、G、B 通道的信息, 然后根据转化公式来间接获取 H、S、V。转化公式如公式 (2-1) ~ (2-3) 所示, 其中 RGB 的取值归一化为[0,1]区间内:

$$H = \begin{cases} 60(R-B)/S, & V = R \\ 120 + 60(B-R)/S, & V = G \\ 240 + 60(R-G)/S, & V = B \end{cases} \quad (2-1)$$

$$S = \begin{cases} (V - \min\{R, G, B\})/V, & V \neq 0 \\ 0, & V = 0 \end{cases} \quad (2-2)$$

$$V = \max\{R, G, B\} \quad (2-3)$$

公式 (2-1) 中, 若 $H < 0$, 则令 $H = H + 360$, 这样能够保证色相 H 的取值范围在 $0 \sim 360^\circ$ 以内。




图 2-5 V 分量灰度直方图

从图 2-5 的 V 分量灰度直方图中可以看出整个眼底图像像素的灰度值分布具有明显的双峰特征, 灰度值偏低的部分为视场外部的暗色背景, 而灰度值偏高的部分则是需要关注的眼底信息。根据 V 分量这明显的双峰特征, 可以直接利用简单的二值分割方法来提取视场, 分割阈值选取为 0.35, 判定式为:

$$\text{mask}(x,y)=\begin{cases} 1, V(x,y)\geq 0.35 \\ 0, V(x,y)< 0.35 \end{cases} \quad (2-4)$$

由于不排除某些眼底图像中 V 分量中视场内灰度值有小于视场外的情况出现，使用二值分割无法确保精确地进行背景与背景的分割，因此还需要对二值分割获得的 mask 图像进行形态学处理。

第一次使用二值分割，视场内将出现少部分暗点，可以采用反色、面积滤波、再反色的形态学处理步骤去除这些暗点。又因为获得的 mask 视场区域应不包含原始图像的边缘区域，所以还要对 mask 图像进行形态学腐蚀，以获得稍小于彩色图像视场边缘的区域。腐蚀采用的结构元素设定为半径 3 的圆盘形。最后获得的 mask 图像如图 2-6 所示。




图 2-6 眼底视场掩模 mask

2.3.2 颜色空间及转换

2.3.2.1 RGB 空间

从眼底照相机上直接获取的是眼底的 RGB 图像，又称为真彩色图像，其每个像素的颜色由像素位置上红色、绿色和蓝色亮度的组合确定。由于每个像素的三种颜色保存在不同的通道中，直接将 RGB 图像转换为灰度图像容易丢失较多的信息。

分别提取 RGB 图像每个颜色通道的灰度图像进行对比，见图 2-7。通过对比发现，不同的通道包含的图像信息由很大的差别。其中红色通道虽然亮度较高，但细节特征无法体现，蓝色通道分量亮度很低，不能辨别所有细节，相比之下，绿色通道中的渗出物和背景的对比度相较原图和其他通道有很大的提高，噪声也较少，可以选择绿色通道的灰度图像作为后续处理的对象。




图 2-7 RGB 通道分量灰度图比较

2.3.2.2 颜色空间转换

CIELab 是一种不常用的色彩空间,其以颜色度量国际标准为基础建立并正式命名为 CIELab 空间。它同时也是一种基于生理特征的,与设备无关的颜色系统。CIELab 空间的建立,说明了人的视觉感应系统是可以数字化描述的。CIELab 色彩空间中的亮度通道 L 取值范围是 $[0,100]$,其中 0 表示纯黑,100 表示纯白,代表像素亮度;颜色通道 a 取值范围是 $[-128, 127]$, -128 表示纯绿,其中 127 表示纯红;颜色通道 b 取值范围也是 $[-128, 127]$, -128 表示纯蓝,127 表示纯黄。可知 L 分量只包含亮度信息,与其他无关; a 和 b 分量只包含颜色信息,与其他信息无关。下图 2-8 所示为 Lab 色彩空间。




图 2-8 LAB 色彩空间

RGB 空间无法直接转 CIELab 空间，需要先把 RGB 空间转到 XYZ 空间再转到 CIELab 空间。具体过程分为两部分：

(1) RGB 空间转 XYZ 空间

设 r , g , b 分别为 RGB 空间的三个通道，取值为 $[0, 255]$ ，转换公式如下：

$$\begin{cases} R = \gamma\left(\frac{r}{255.0}\right) \\ G = \gamma\left(\frac{g}{255.0}\right) \\ B = \gamma\left(\frac{b}{255.0}\right) \end{cases} \quad (2-5)$$

式中 γ 函数是用来对图象进行非线性色调编辑的，目的是提高图像对比度。其表达式为：

$$\gamma(x) = \begin{cases} \left(\frac{x + 0.055}{1.055}\right)^{2.4}, & x > 0.04045 \\ \frac{x}{12.92}, & \text{otherwise} \end{cases} \quad (2-6)$$

然后利用 RGB 和 XYZ 的转化关系式：

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} 0.4361 & 0.3851 & 0.1431 \\ 0.2225 & 0.7169 & 0.0606 \\ 0.0139 & 0.0971 & 0.7142 \end{bmatrix} * \begin{bmatrix} R \\ G \\ B \end{bmatrix} \quad (2-7)$$

即可得 XYZ 空间。

(2) XYZ 空间转 CIELab 空间

设 X, Y, Z 分别为 XYZ 空间三个通道, 转换公式如下:

$$\begin{cases} L = 116 * (Y / Y_n) - 16 \\ a = 500 * [f(X / X_n) - f(Y / Y_n)] \\ b = 200 * [f(Y / Y_n) - f(Z / Z_n)] \end{cases} \quad (2-8)$$

式中 X_n, Y_n, Z_n 默认为 1, 函数 f 的表达式如下:

$$f(t) = \begin{cases} t^{\frac{1}{3}}, & t > (\frac{6}{29})^3 \\ \frac{1}{3} * (\frac{29}{6})^2 * t + \frac{4}{29}, & otherwise \end{cases} \quad (2-9)$$

至此图像从 RGB 空间转到 CIELab 空间。

2.4 阈值分割

2.4.1 阈值分割简介

阈值分割^[22]是基于区域的图像分割技术。由于阈值分割具有实现简单、运算量小等特点, 成为应用最广泛的图像分割技术。对于目标和背景灰度差异明显的图像特别适用, 不仅可以极大的压缩数据量, 从而大大减少运算量, 而且能够简化分析处理的步骤。可以说阈值分割是进行图像处理前的必要的图像预处理过程。

2.4.2 阈值分割原理

图像阈值化的是利用灰度的不同, 对像素集合进行划分, 划分得到的子集都是一个感兴趣区域, 任一区域内部具有一致的属性。一般可以根据图像的灰度特点, 选取一个或多个阈值把眼底图像划分多个区域。

根据图像的灰度特征, 选择不同的阈值, 把像素集合分为若干个一致区域。一般常用特征主要包括以下两种:

- (1) 图像灰度的特征值;
- (2) 通过灰度变换得到的特征值。

设原始图像为 $f(i,j)$, 根据图像的灰度特征找到特征值 T, 可将原始图像分成两个部分, 分割后的图像 $g(i,j)$ 为:

$$g(i, j) = \begin{cases} 1, & f(i, j) \geq T \\ 0, & f(i, j) < T \end{cases} \quad (2-10)$$

这就是图像二值化。

2.5 数学形态学处理

2.5.1 数学形态学简介

数学形态学是以数学理论分支中的几何学为基础建立的,利用结构元素来探测图像中物体的形状,不一样的结构元素选择会带来完全不同的处理结果。因此首先需要通过具体分析图像的特征,然后选择合适的结构元素,这样才能获得理想的结果,这充分体现出形态学很强的灵活性。总之,结构元素的选择是数学形态学算法最关键的部分,不同结构元素的选择对应着不同的几何信息分析和处理。

在本课题中,数学形态学处理的对象是二值化分割出的包含渗出物区域与噪声信息的图像,涉及到的形态学分支被称为“二值形态学”(Binary Morphology)。二值形态学中将二值图中的不同区域看成不同的数据集合,这样便可以运用最简单的集合和几何运算对二值图进行处理。因为二值形态学是基于集合进行的运算,数学兼容性好且易于实现,因此可以运用它来对眼底视网膜图像进行很多的优化处理,如去噪、边界检测和区域分割等。同时,通过这些处理方法,可以实现维持需要的渗出物区域不受太大影响的同时剔除不需要的非渗出物结构。下面来简要介绍一下本文中所使用到的数学形态学运算。

2.5.2 本文使用的形态学运算

(1) 膨胀与腐蚀

膨胀^[9]是在二值图像中“加长”或“变粗”的操作,能够把和感兴趣区域接触的外部背景像素点合并到该区域内,使得区域边界向外扩张,一般可用于填补区域内部的空洞。数学上,膨胀定义为几何运算。A 被 B 膨胀,记为 $A \oplus B$, 定义为

$$A \oplus B = \{z | (\hat{B})_z \cap A \neq \emptyset\} \quad (2-11)$$

式中, B 为结构元素, \emptyset 为空集。换言之, A 被 B 膨胀可看做全部结构元素原点位置的像素集合,同时映射和平移后的 B 与 A 的必然存在部分重叠。

腐蚀^[9]能够“收缩”或“细化”二值图像中的对象,能够消除边界像素点,使区域的边界向内部收缩,一般可用于消除细小无用的区域。其定义与膨胀相似, A 被 B 腐蚀记为 $A \ominus B$, 定义为

$$A \ominus B = \{z | (B)_z \cap A^c = \emptyset\} \quad (2-12)$$

式中, B 为结构元素, \emptyset 为空集。总之, A 被 B 腐蚀可看做全部结构元素原点位置的像素集合,同时平移的 B 与 A 的背景不发生叠加。

在本文处理过程中,膨胀与腐蚀效果对比如图 2-9 所示。经对比表明,经过膨胀、腐蚀的处理,区域的连通性得到了改善。




图 2-9 数学形态学用于区域连通

此外,腐蚀还用于视场掩模 mask 图像的处理,上一节已作介绍,不再赘述。

(2) 开、闭运算

A 被 B 的形态学开运算^[19]可以记做 $A \circ B$ ，一般用于消除小区域，分离边界连接很少的区域，平滑较大区域的边界，而且可以几乎不改变区域面积。这种运算时 A 被 B 腐蚀后再用 B 来膨胀腐蚀结果：

$$A \circ B = (A \ominus B) \oplus B \quad (2-13)$$

A 被 B 的形态学闭运算^[19]记做 $A \bullet B$ ，一般用于填充区域内细小空洞，连接边界很近的区域，平滑区域的边界，而且可以几乎不改变区域面积。它是先膨胀再腐蚀的结果：

$$A \bullet B = (A \oplus B) \ominus B \quad (2-14)$$

从几何学上讲， $A \bullet B$ 是所有不与 A 重叠的 B 的平移的并集。

在本文算法处理过程中，闭运算可用于填充渗出物区域中比结构元素小的空洞，使渗出物区域变得丰满，如图 2-10 所示：



(a) 处理前，渗出物区域内部含空洞 (b) 处理后，渗出物内部空洞消失

图 2-10 闭运算处理对比

2.6 K 均值聚类

K 均值聚类算法^[14]是硬聚类算法，是一种基于原型的目标函数聚类方法，是数据样点到原型的某种距离作为优化目标函数，然后利用函数求极值的方法来获得迭代运算的调整规则。K 均值聚类算法通常把欧式距离作为相似度测度，通过求对应某初始聚类中心向量 V 的最优分类，从而使得评价指标最小。该算法采用误差平方和准则函数作为聚类准则函数。k 均值聚类的一般流程：

- (1) 从 n 个数据对象中任选 k 个作为初始的聚类中心；
- (2) 根据每个聚类对象的均值（聚类中心），计算每个对象与这些聚类中心的距离；并依据最小距离重新划分相应对象；
- (3) 重新计算每个有变化的聚类的均值（聚类中心）
- (4) 计算测度函数，当满足一定条件，比如函数收敛时，则算法终止；如果条件不满足则回到步骤 (2)

k 个聚类具有以下特点：各聚类本身尽可能的紧凑，而各聚类之间尽可能的分开。

K 均值聚类算法优点：

- (1) 算法快速简单；
- (2) 时间复杂度接近线性，适用于大量的数据处理。

K 均值聚类算法缺点：

- (1) 对初始的聚类中心很敏感，容易出现局部最小值；
- (2) 事先需要指定 k 值，然而 k 值难以估计。

2.7 本章小结

本章介绍了视网膜渗出物检测的基础知识，包括视网膜生理结构、视场提取与通道转换以及数学形态学处理等内容。其中，视网膜的生理结构部分还介绍了病变视网膜图像的一些非渗出物结构，为接下来视网膜图像的处理和研究做好铺垫；数学形态学部分介绍了许多后面处理过程中必不可少的形态学运算，在渗出物检测整个过程中发挥着重要的作用。以上的这些内容作为本文课题研究的基础知识进行概括介绍，为下一步的深入研究奠定基础。

第三章 渗出物检测算法研究

3.1 基于 SVM 的眼底图像渗出物检测

3.1.1 SVM 简介

支持向量机^[23](Support Vector Machine, SVM)的数学基础是统计学习理论。SVM 仅针对线性可分的情况,但在实际应用中可以通过特殊的数学变换,使得 SVM 能够支持线性不可分的情况。

SVM 的主要思想可以概括为两点:

- (1) SVM 本身只适用于线性可分的情况。
- (2) 对于线性不可分情况,需要特殊的数学变换把低维空间线性不可分样本转成高维空间的线性可分样本,这样就可以在高维空间继续利用 SVM 进行分析。

3.1.2 SVM 核函数

对于线性可分样本, SVM 可以直接处理。但是实际大部分数据都是线性不可分的,因此需要通过特殊的数学变换将低维空间线性不可分数据转成高维空间线性可分数据。这一特殊的数学变换就是核函数。利用核函数可以获得高维空间的线性可分数据,同时可以证明在高维空间建立 SVM 学习机几乎不会增加计算的复杂性。

下面是 3 种常用的核函数:

(1) 线性核函数(Linear Kernel) $k(x_i, x) = \langle x_i, x \rangle$ (3-1)

(2) 多项式核函数(Polynomial Kernel) $k(x_i, x) = (\langle x_i, x \rangle + 1)^d$ (3-2)

(3) 径向基函数(Radial Basis Function) $k(x_i, x) = \exp(-\frac{\|x_i - x\|^2}{\sigma^2})$ (3-3)

3.1.3 霍夫变换

霍夫变换^[6](Hough Transform)是一种基于投票算法的特征提取技术,可以用来检测具有特定形状的物体。该过程在一个参数空间中通过计算累计结果的局部最大值 得到一个符合该特定形状的集合作为霍夫变换结果。霍夫变换由 Paul Hough 首次提出,后由 Richard Duda 等推广使用,霍夫变换不仅可以用来检测图像中的直线,也可以对任意形状物体的识别,尤其被广泛应用在圆或椭圆的检测中。霍夫变换运用两个坐标空间之间的变换将在一个空间中具有相同形状的曲线或直线映射到另一个坐标空间的一个点上形成峰值,从而把检测任意形状的问题转化为统计峰值问题。

3.1.4 算法流程与结果

详细的处理步骤为:

第一步 将原始图像转化为灰度图如图 3-1 (a);

第二步 对灰度图使用半径为 13 的圆盘结构元素进行数学形态学开运算,可以获得其

背景图，如图 3-1 (b)；

第三步 把背景图从灰度图中减去可得到前景图，如图 3-1 (c)；

第四步 设置阈值 $T=21$ 对前景图进行阈值分割，得到渗出物候选区域，如图 3-1 (d)；

第五步 利用霍夫变换检测视盘^[6]，如图 3-1 (e)；

第六步 从候选区域中剔除视盘，即可得渗出物的粗分割，如图 3-1 (f)；




图 3-1 眼底图像渗出物候选区域

通过比较候选区域和对应眼底图像的专家手工分割真值图，如图 3-2 所示。可以发现 DIARETDB1 数据库给出的硬性渗出物的专家分割结果是基于区域划分的，渗出物的边界过于粗糙^[1]，无法获得准确的分类标记，如果直接用来训练分类器，必然导致分类器准确率大大降低。因此如果一定要训练分类器，只能寻找眼科专家对已有的专家分割结果做进一步的详细划分，已获得精确的手 工分割结果。由于客观条件限制，无法获得精确的手 工分割结

果，因此无法训练分类器。同时考虑 SVM 属于监督类的机器学习算法，这说明基于现有的材料不足以实现监督类的机器学习算法，为后面的算法研究提供了一定方向。




图 3-2 专家手工分割结果

算法流程如图 3-3 所示：

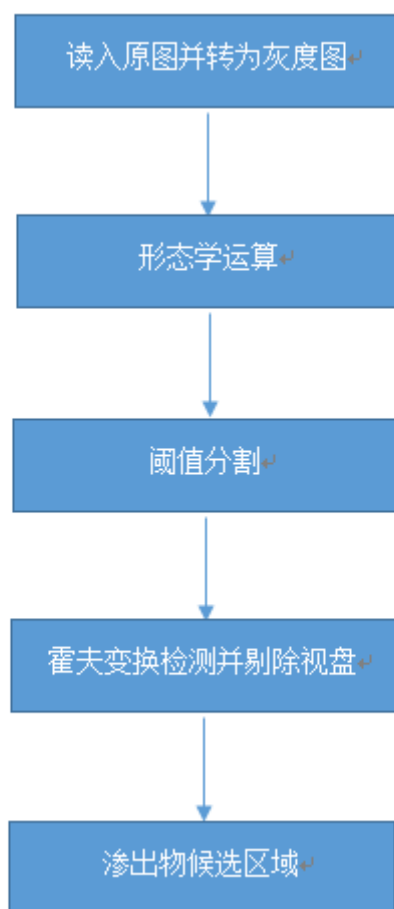


图 3-3 算法流程框图

由于不能使用 SVM 对渗出物候选区域进行精分割，而且该算法是基于渗出物与背景之间灰度存在明显差异，同时考虑到存在眼底图像的光照条件、对比度差等因素，所以该算法并不能区分硬性渗出物和软性渗出物，有极大可能渗出物候选区域存在软性渗出物，从而影响算法的检测精度。该算法检测的渗出物通过阈值分割获得，因此渗出物的边缘清晰，符合实际渗出物边缘清晰的特点。但渗出物区域不够饱满，并没有完全把渗出物从原始图像中提取出来，会降低分割灵敏度。对于利用霍夫变换检测视盘过程中，需要依赖于血管网络，以至于视盘检测精度低于血管网络检测精度，同时增加了计算复杂度。

针对上述视网膜渗出物提取算法检测精度不高的问题，提出了一种融合重建滤波器和暗特征的视网膜渗出物检测算法。

3.2 融合重建滤波器和暗特征的渗出物检测

3.2.1 Top-hat 变换

Top-hat 变换^[24]是指原图像与开或闭运算后的图像做差，可用于增强阴影的细节。白 Top-hat 变换是指原图像减去开运算后图像，可用于提取灰度图像内尺寸小于结构元素的峰值，也就是所谓的亮特征；黑 Top-hat 变换是指闭运算后图像减去原图像，可用于提取灰度图像内尺寸小于结构元素的谷值，也就是所谓的暗特征。

Top-hat 的数学定义如下：

$$H(x,y) = I(x,y) - (I(x,y) \circ b) \quad (3-4)$$

其中 $I(x,y)$ 为输入灰度图像， b 为结构元素， (\circ) 表示开运算。

利用 Top-hat 变换处理图像时，结构元素的选择是相当关键的一步，一般根据所要增强的信息来决定采用什么结构元素以及结构元素的大小。

3.2.2 限制对比度直方图均衡化

限制对比度直方图均衡化与一般自适应直方图均衡不同的地方主要表现在其对比度限幅。在限制对比度直方图均衡化中，对于每个小区域都必须使用对比度限幅。限制对比度直方图均衡化主要是用来克服自适应直方图均衡化的过度放大噪音的问题。

这主要是通过限制自适应直方图均衡化算法的对比提高程度来达到的。在指定的像素值周边的对比度放大主要是由变换函数的斜度决定的，这个斜度和领域的累积直方图的斜度成比例。限制对比度直方图均衡化通过在计算像素周边的累积直方图函数前用预先定义的阈值来裁剪直方图以达到限制放大幅度的目的，同时这也限制了像素周边的累积直方图函数的斜度，从而限制了变换函数的斜度。直方图被裁剪的值，也就是裁剪限幅，取决于直方图的分布。通常，直接忽略掉那些超出直方图裁剪限幅的部分是不好的，而应该将这些裁剪掉的部分均匀的分布到直方图的其他部分，如图 3-4 所示。




图 3-4 限制对比度直方图均衡化示意图

3.2.3 算法流程与结果

第一步 对原始图像的灰度图进行尺寸重置，利用均值滤波去噪，采用如下公式：

$$\overline{f(i,j)} = \frac{1}{m * n} \sum_{i=1, j=1}^{i=m, j=n} f(i,j) \quad (3-5)$$

式中： $m=n=17$ ； $f(i,j)$ 为图像坐标在 (i,j) 处的灰度值； $\overline{f(i,j)}$ 是滤波后的灰度值。同时利用限制对比度直方图均衡化增强灰度图像对比度，如图 3-5 (a)；

第二步 利用形态学闭运算重建滤波器移除血管，利用滑动列滤波器检测渗出物区域，并对其进行阈值分割，如图 3-5 (b)；

第三步 提取眼底图像的边界，如图 3-5 (c)。

第四步 首先计算图像中每一列的局部最大值，接着确定所有局部最大值的像素点坐标，如果不止一个像素点，那么就取中值代替，并以此点为圆心创建视盘掩膜，如图 3-5 (d)。因此掩膜的半径可以用

$$R^2 = (x - h)^2 + (y - k)^2 \quad (3-6)$$

计算。式中： R 为掩膜半径， h 和 k 分别为最亮点的横纵坐标。

第五步 将阈值分割之后的渗出物区域剔除边界和视盘，利用形态学闭操作重建滤波器填充渗出物区域，同时扩大尺寸，如图 3-5 (e)。

第六步 运用 Top-hat 变换提取暗特征，并将填充后的渗出物区域与暗特征进行逻辑与运算，可得到最终渗出物，如图 3-5 (f)。




图 3-5 眼底图像渗出物

图 3-6 为算法流程框图：

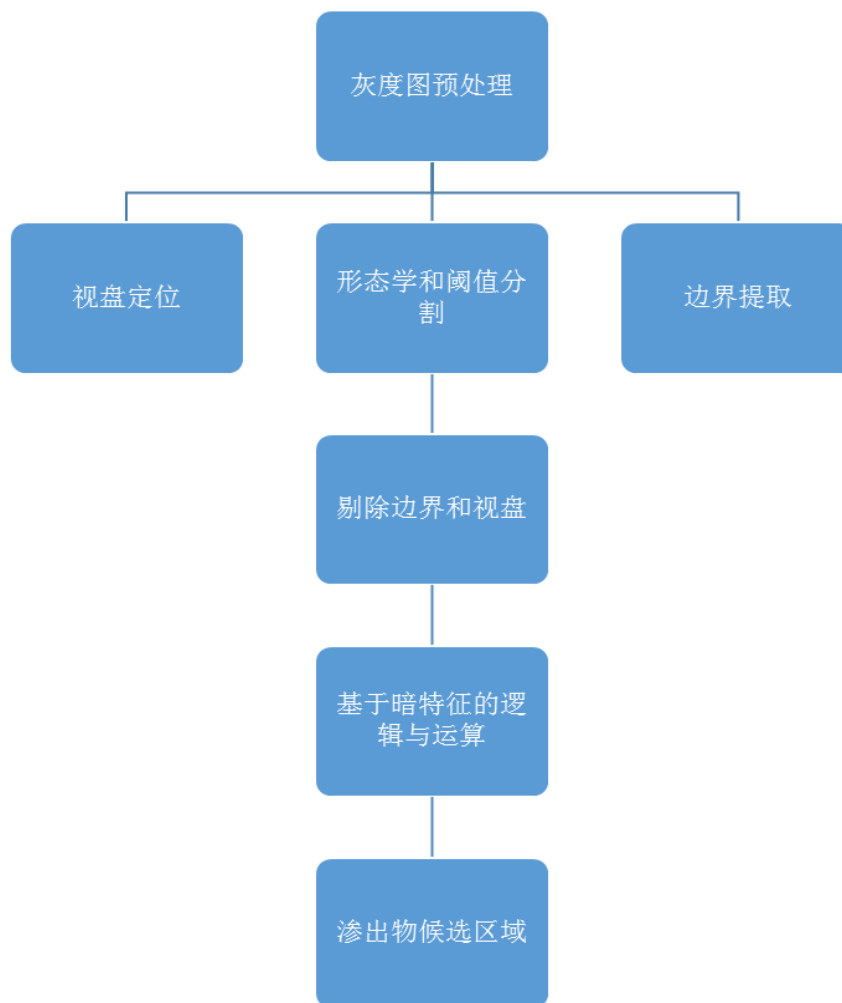


图 3-6 算法流程框图

该算法检测的渗出物区域相对饱满，但是由于渗出物区域是通过形态学重建获得，会导致渗出物区域的边缘模糊，与实际渗出物边缘清晰的特点不符合。同时由于该算法只利用了渗出物的亮度和灰度特征，没有考虑其他特点，较容易收到噪声的影响，因此在预处理阶段使用均值滤波滤去噪声，以减小对后期渗出物检测的影响。该算法的创新点在于视盘定位方法的改变，相较于 3.1 节中视盘检测依赖血管网络分布，本文方法利用视盘由明亮斑点组成这一特点，不依赖其他信息直接定位视盘，有较高的运算效率，同时能够保证视盘的检测精度。

3.3 本章小结


本章介绍了两种眼底图像渗出物检测的算法，一种是基于 SVM 的分类算法，另一种是基于形态学分割的算法。通过研究分析发现，现有的材料不足以完成基于监督的 SVM 分类算法，需要进一步对自带的真值图做精细分割，才能完成完整算法。因此，当前情况下该算法只能获得粗分割的渗出物区域，同时说明基于监督的机器学习算法都不可行。此渗出物区域边缘清晰，但渗出物检出率不高，不够饱满。基于形态学分割的算法有很高的运算效率，耗时短等特点，同时该算法检测的渗出物区域的检出率高，相对比较饱满，但渗出物边缘不够清晰。这两种算法都只是改善图像质量，并没有对视网膜眼底图像内容做深度挖掘，因此都部分或完全忽视了棉绒斑、黄斑反射等干扰对渗出物检测的影响。

第四章 改进 K 均值聚类检测算法

4.1 改进思路的产生

通过前一章的介绍说明,发现前面两种算法都是在 RGB 色彩空间完成的,RGB 色彩空间的颜色信息,亮度信息等各种信息混杂,在对眼底图像某些信息进行增强的时候,必然会放大另外的部分信息,从而影响渗出物检测的结果。而且前面两种算法一种属于阈值分割的算法,另一种属于形态学分割的算法,这两种算法虽然计算简单,耗时很短,但都存在的问题。考虑到机器学习算法的优势,同时由于基于监督的机器学习算法不可实现,因此可以选择非监督类的机器学习算法,模糊 C 均值聚类算法和 K 均值聚类是最常见的非监督机器学习算法。

通过大量参阅相关论文后发现,Rajput 等^[14]对 Lab 色彩空间运用 K 均值聚类结合分类器的方法区分硬性渗出物和软性渗出物。首先通过对 Lab 色彩空间进行 K 均值聚类初步分离出视网膜渗出物和非渗出物,接着利用形态学闭运算去除血管,然后利用霍夫圆变换剔除视盘这一非阳性区域,最后利用边缘强度和阈值作为特征来进行分类区分硬性渗出物和软性渗出物。图 4-1 所示为该算法最后的检测结果。由于 DIARETDB1 数据库给出的硬性渗出物的专家分割结果是基于区域划分的,渗出物的边界过于粗糙^[1],因此无法完成通过分类法区分硬性渗出物和软性渗出物的过程。



(a)原始图像



(b)渗出物图像




图 4-1 渗出物检测结果

Gaikwad 等^[25]也提出了对 Lab 色彩空间运用 K 均值聚类检测渗出物的算法。第一步进行预处理。通过将眼底图像从 RGB 色彩空间转换到 HSI 色彩空间，然后对亮度通道 I 进行中值滤波去除噪声，同时利用自适应直方图均衡化对滤波后的亮度通道 I 进行对比度增强，最后将处理后的 HSI 空间转回 RGB 空间。第二步 K 均值聚类。将增强后的图像从 RGB 空间转到 CIELab 空间，然后对 Lab 空间的颜色通道 a 和 b 进行 K 均值聚类，获得只包含渗出物和视盘的标记图像。第三步视盘检测。利用形态学的方法，提取标记图像中面积最大的区域，此即为视盘。最后从含有渗出物和视盘的标记图像中剔除视盘，即可获得渗出物区域，图 4-2 为该算法最后的检测结果。




图 4-2 渗出物检测结果

该文提供的算法有很好的可行性，属于无监督的机器学习算法，因此以该算法为基础，做出相应的改进算法。通过第二章关于 K 均值聚类的介绍，了解到 K 均值聚类的关键问题在于两点：

- (1) 初始聚类中心的选择；
- (2) 聚类数目的确定；

该文的初始聚类中心是随机选择的，并没有给出相应的优化方案，也就是说可能存在某些情况，随机选择获得的初始聚类中心是没有实际意义的噪声点，导致最后的聚类结果不理想甚至聚类失败，因此需要在此处做改进，选择合适的优化方案。可能是考虑到不同数据库的眼底图像存在各种各样的差异，对应着不同的聚类数目，因此该文并没有给出明确的聚类数目。同时考虑到该算法处理的数据库是非公开，与本文使用的公开的 DIARETDB1 数据库不同，因此需要在此处做改进，从而确定合适的聚类数目。在视盘检测阶段，该算法也存

在一定的范围。该算法对含有渗出物和视盘的标记图像进行形态学闭运算，连接分散的视盘区域。可以发现视盘之间存在很大的空隙，如果使用形态学闭运算进行连接，需要尺寸很大的结构元素，必然影响渗出物的检测效果。因此需要寻找合适的视盘检测方法。

4.2 算法的改进点

针对前一节中提到的算法中可能存在的三个问题：

- (1) 初始聚类中心的选择；
- (2) 聚类数目的确定；
- (3) 视盘检测。

本小节主要是针对以上存在的问题，提出相应的解决方案，以避免这些问题可能对渗出物检测带来的不利影响。

4.2.1 初始聚类中心的选择

原算法中并没有对初始聚类中心的选择进行优化，可能会出现因为初始聚类中心选择不当导致聚类失败的情况，因此必须优化改进初始聚类中心的选择。通过查阅大量相关文献，发现可以引入数据密度的概念对初始聚类中心的选择进行优化改进。传统的 K 均值聚类对初始聚类中心很敏感，通常不同的初始聚类中心对应着不同的聚类结果。在使用欧氏距离作为相似性测度的 K 均值聚类算法中，一般选择距离最远的 k 个数据比随机选择 k 个数据更具有代表性。然而实际的数据集通常存在噪声数据，如果只是简单地选择距离最远的 k 个点，有时可能会取到噪声点，最终影响聚类效果。一般认为噪声数据总是少量、分散的，处于低密度区域，而有效数据总是大量聚集的，处于高密度区域^[26]。因此为了避免取到噪声点，可以从高密度区域选择距离最远的 k 个点作为初始聚类中心。

选择眼底灰度图像作为处理对象，做出其灰度直方图，接着观察灰度直方图的灰度分布，选择合适的灰度值作为阈值，然后对灰度图像进行阈值分割，可以保留图像主要的灰度信息，此就是待处理的数据集合。以图 4-3 为例进行具体说明，观察图 4-3 可以发现灰度信息主要集中在[50 150]，为了保留主要的灰度信息，可以选择小于 50 的阈值对灰度图进行分割。比如选择阈值 $T=20$ 对其进行阈值分割，就可以得到待处理的数据集合。

为了计算数据所在区域的密度，首先定义一个密度参数：以数据 A_i 为中心，包含常数个非零数据的最小圆的半径称之为 A_i 的密度参数。密度参数越大，说明数据所在区域的密度越低。相反地，密度参数越小，说明数据所在区域的密度越高。因此可以通过计算每个数据的密度参数，然后获得一个高密度点集合 P 。下面是选择 k 个初始聚类中心的具体过程：首先，在高密度点集合 P 中选择最高密度的数据点作为第一个初始聚类中心 x_1 ；选择高密度点集合 P 中距离 x_1 最远的数据点作为第二个初始聚类中心 x_2 ；计算高密度点集合 P 中数据点 m_i 到 x_1, x_2 的欧氏距离 $d(m_i, x_1), d(m_i, x_2)$ ，初始聚类中心 x_3 是满足

$$\max(\min(d(m_i, x_1), d(m_i, x_2))), i = 1, 2, \dots, n \quad (4-1)$$

的数据点 m_i ； x_q 是满足

$$\max(\min(d(m_i, x_1), d(m_i, x_2), \dots, d(m_i, x_{q-1}))), i = 1, 2, \dots, n \quad (4-2)$$

的数据点 m_i 。依次类推可以获得优化后的 k 个初始聚类中心。




图 4-3 灰度直方图

4.2.2 聚类数目 k 的确定

原算法中没有给出具体的聚类数目 k ，也没有给出如何确定 k 的方法，然而聚类数目 k 又是 K 均值聚类算法的关键参数，因此需要确定合适聚类数目 k 。由于算法的基本思路是利用渗出物的颜色明亮、边缘清晰等特征，对 CIELab 空间的颜色通道 a 和 b 进行 K 均值聚类，通过调节聚类数目，使得聚类得到的结果只含有渗出物或者只含有渗出物以及极少的干扰。下面通过实验直观比较，不同聚类数目得到的聚类结果，然后给出合适的聚类数目。图 4-4 为 $k=3$ 的聚类结果。




图 4-4 $k=3$ 聚类结果

可以看到 $k=3$ 时包含渗出物的标记图像，图 4-4 (c) 存在很多干扰，不能从中提取渗出物区域。图 4-5 为 $k=4$ 的聚类结果。




图 4-5 $k=4$ 聚类结果

可以看到 $k=4$ 时包含渗出物的标记图像，图 4-5 (a) 虽然较图 4-4 (c) 有很好的改进，但渗出物周围仍然存在明显的非渗出物干扰，并且此干扰难以剔除。图 4-6 为 $k=5$ 的聚类结果。




图 4-6 $k=5$ 聚类结果

可以看到 $k=5$ 时包含渗出物的标记图像，图 4-6 (e) 虽然较图 4-5 (a) 有所改进，渗

出物周围检测到的非渗出物明显减少，但渗出物周围仍然存在的非渗出物干扰，再次增加聚类数目尝试完全将其剔除。图 4-6 为 $k=6$ 的聚类结果。




图 4-7 $k=6$ 聚类结果

可以看到 $k=6$ 时包含渗出物的标记图像，图 4-7 (c) 较图 4-6 (e) 的改进已经很小，但是通过计算发现渗出物周围检测到的非渗出物有所减少，但几乎可忽略。这说明通过增加聚类数目提高渗出物检出率的方法效果已经很差，因此继续增加聚类数目的意义不大。而图 4-7 (c) 较图 4-6 (e) 有相对清晰的边缘，符合渗出物的本身的边缘特点。通过设置聚类数目 $k=6$ ，对 DIARETDB1 数据库中眼底图像进行 K 均值聚类，发现能够获得较理想的聚类结果。因此对于 DIARETDB1 数据库而言，本算法可以选择聚类数目 $k=6$ 作为最终的聚类参数。需要说明的是，此聚类数目可能并不适用于其他数据库，在使用其他数据库时需要重新设置合适的聚类数目。

4.2.3 视盘检测

原算法对含有渗出物和视盘的标记图像进行形态学闭运算，用来连接分散的视盘区域。但是视盘区域之间存在很大的空隙，如果使用形态学闭运算将分散的视盘区域进行连接，则需要尺寸很大的结构元素，但同时也会改变渗出物区域，见图 4-8。从图中可以发现部分渗出物区域连通了，渗出物面积和边缘均发生了改变，对渗出物检测造成很大影响。依据视盘是由明亮的斑点组成这一特点，可以通过寻找亮度最大的斑点来进行视盘定位^[8]。为了保护其他细节信息不受干扰，可以利用视盘掩膜对其进行保护。一般选择经均值滤波和对比度增强后的灰度图像为处理对象，首先计算图像中每一列的局部最大值，接着确定所有局部最大值的像素点坐标，由于局部最大值的像素点可能不止一个，那么可以用他们的中值代替，并以此点为圆心创建视盘掩膜，因此掩膜可以用

$$R^2 = (x - h)^2 + (y - k)^2 \quad (4-3)$$

计算。式中： R 为掩膜半径，对于同一数据库而言，视盘占图像的比例几乎相同，掩膜半径可以根据眼底图像实际尺寸进行设置， h 和 k 分别为最亮点的横纵坐标。将视盘掩膜反转与包含渗出物和视盘的标记图像进行逻辑与运算就能获得渗出物图像。图 4-9 是改进方法检测视盘的结果，由于其只处理了视盘区域，因此几乎不会对渗出物检测产生影响，相较于原来

的视盘检测算法有较大改进。

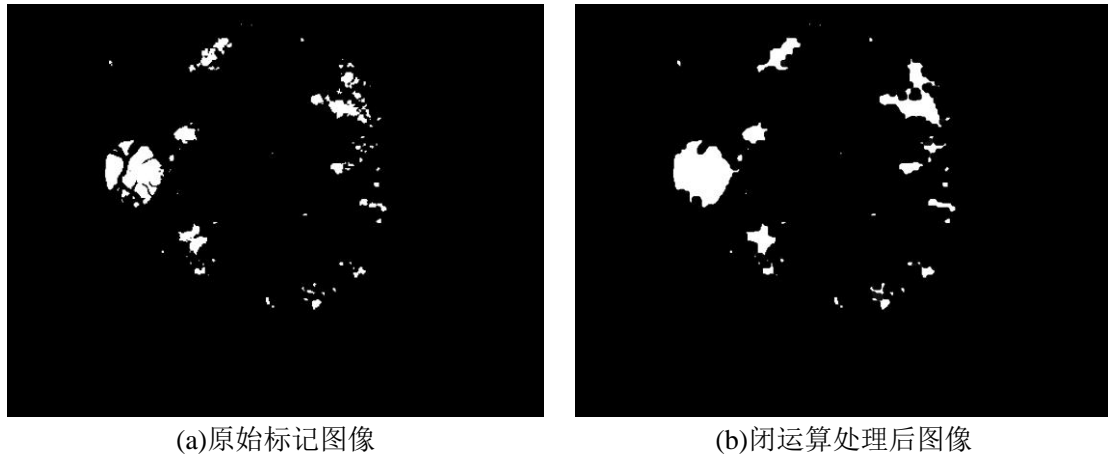


图 4-8 原始视盘检测图像




图 4-9 改进后视盘检测图像

4.3 改进后的算法流程与结果

具体步骤如下：

第一步-预处理 亮度信息作为渗出物的一个重要特点，可以用来区分渗出物和非渗出物区域。由于各种原因导致图像存在噪声，同时因为光照不均衡导致对比度下降，因此首先需要对图像进行增强。考虑到 HSI 色彩空间的 I 通道只含有亮度信息，可以先将图像从 RGB 空间转到 HSI 空间，可以选择亮度通道 I 作为对象，见图 4-10 (a)，对其进行中值滤波去除噪声，利用限制对比度自适应直方图来增强对比度，得到增强后亮度通道 I，见图 4-10(b)，最后再将图像从 HSI 空间转回 RGB 空间，见图 4-10 (c)。

第二步-K 均值聚类 前一章的算法均是利用亮度或者灰度特征提取渗出物，忽视了渗出物的颜色特征。渗出物表现为亮黄色，具有强烈的颜色特征，而且有清晰的边缘，因此考虑利用渗出物的颜色特征在 Lab 色彩空间进行处理。Lab 空间中 a 层和 b 层均为色度层，同时包含了所有的颜色信息，可用于基于颜色的图像分割，因此可以用色度层来做 K 均值聚类。在 K 均值聚类实现过程中使用欧氏距离作为相似度测度，参考前一节的分析，引入区域密度指标选择合适的初始聚类中心，当聚类数目为 6 时，可以提取得到只含有渗出物和视盘的候选区域，见图 4-10 (d)。

第三步-视盘定位 利用视盘由明亮的斑点组成这一特点，首先计算图像中每一列的局部最大值，接着确定所有局部最大值的像素点坐标，由于局部最大值的像素点可能不止一个，

那么可以用他们的中值代替，并以此点为圆心创建视盘掩膜，见图 4-10 (e)

第四步-剔除视盘 从候选区域中剔除视盘，即可以获得真实的渗出物区域，见图 4-10 (f)。




图 4-10 渗出物候选区域

图 4-11 所示为改进算法的流程图。

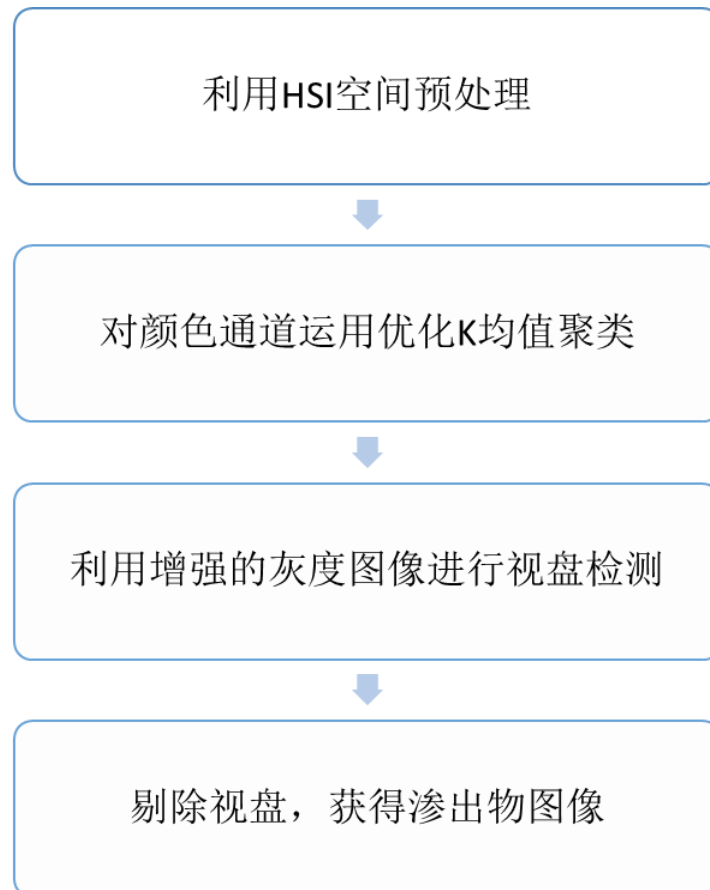


图 4-11 改进算法流程框图

该改进算法利用不仅充分利用了渗出物的颜色信息、亮度信息，而且利用了渗出物边缘清晰的特点。利用 CIELab 色彩空间 L 通道只包含亮度信息，与其他信息无关；a 通道和 b 通道只含有颜色信息，与其他信息无关的特点，通过提取颜色通道 a 和 b 来做 K 均值聚类得到的标记图像，理论上可以使得渗出物区域饱满，保证相当高的检出率。同时通过对比度增强，使得渗出物区域的边缘在颜色通道中更加清晰，在做 K 均值聚类的时候，理论上也能够保证提取出清晰的边缘。从实际的实验结果中也可以看出，本章的改进算法对渗出物检测的准确度较高，同时保留细节信息较多，在保持渗出物区域边缘较清晰的同时，尽量提高渗出物的检出率，使得渗出物区域饱满，使算法性能得到提升，算法的具体性能指标和比较将在第五章给出。

4.4 本章小结

本章改进了基于 CIELab 色彩空间和 K 均值聚类算法的渗出物检测算法，该算法的设计目标是很好地继承前一章介绍的两种算法的优点，在保持渗出物区域边缘较清晰的同时，尽量提高渗出物的检出率，使得渗出物区域饱满，使算法性能得到提升。本章首先介绍了改进算法的关键内容，接着从一些关键问题入手，讨论该改进算法的可行性，然后通过实验选择合适的实验参数，最后确定了一个较为合理的算法实施步骤。

第五章 实验结果

5.1 DIARETDB1 图像库介绍

本文使用的是公开数据库 DIARETDB1^[27](Standard Diabetic Retinopathy Database Calibration level 1, version 1)。此数据库一共包含 89 幅彩色视网膜眼底图像，每幅图像均以像素分辨率 1500*1200，每个像素 24 位的 PNG 格式存储。这些彩色眼底图像来源于一个普查项目，均由眼底相机以 50° 的角度进行拍摄，是眼科专家从大量的来自不同患者的彩色眼底图像中手工挑选获得。对于图像本身分布而言，它没有对应于特定的群体，因此具有很强的代表性。在所有 89 幅图像中，有 6 幅图像是完全正常的，没有任何病变，剩余的 83 幅图像均存在不同程度病变：其中包含硬性渗出物的 47 幅，包含棉绒斑的 33 幅，其它存在出血斑或者微动脉瘤等病变。需要说明的是同一幅图像上可能同时存在上述不同种类的病变，因此在自动检测的时候需要考虑相互干扰。

DIARETDB1 数据库自带了每一幅图像病变分割的参考结果，该参考结果是四名专家手动标注得到的。通过观察图 5-1，可以发现参考结果是基于区域划分的，硬性渗出物的边缘划分过于粗糙。图中亮区域表明专家认为这个区域可能包含病变，亮度越高表示各个专家分割的一致性越高，说明该区域包含病变的概率越高。根据该数据库自带的使用说明，如果参考结果中该区域的亮度不低于最大亮度的 75%，那么可以视为该区域发生了病变。




图 5-1 DIARETDB1 数据库自带专家分割结果

5.2 分割结果

PC 实验环境为 CPU: Intel(R) Core(TM) i3-M370 2.40GHz, RAM: 6.00GB, MATLAB

R2014a 系统: win7 sp1 x64。




图 5-2 眼底图像库渗出物检测结果

图 5-2 为实验结果对比图。图中第一行是原始视网膜图像，第二行是作为标准的专家手动分割结果，第三行是基于阈值分割的检测算法的分割结果，第四行是基于形态学的检测算法的分割结果，最后一行是本文的改进算法，即基于 K 均值聚类的检测算法的分割结果。

基于阈值分割的检测算法是利用渗出物与背景之间灰度存在明显差异这一特点完成的，然而考虑到存在眼底图像的光照条件、对比度差等因素，所以该算法并不能区分硬性渗出物和软性渗出物，有极大可能渗出物候选区域存在软性渗出物，从而影响算法的检测精度。由

于该算法检测得到的渗出物区域是通过阈值分割获得,因此渗出物的边缘清晰,符合实际渗出物边缘清晰的特点。但渗出物区域不够饱满,并没有完全把渗出物从原始图像中提取出来,会降低分割灵敏度。基于形态学的检测算法检测出的渗出物区域相对饱满,但是由于渗出物区域是通过形态学重建获得,会导致渗出物区域的边缘模糊,与实际渗出物边缘清晰的特点不符合。同时由于该算法只利用了渗出物的灰度特征,没有考虑其他特点,较容易收到噪声的影响,因此在预处理阶段使用均值滤波滤去噪声,以减小对后期渗出物检测的影响。基于K均值聚类的改进算法利用不仅充分利用了渗出物的颜色信息,而且利用了渗出物边缘清晰的特点。利用CIELab色彩空间L通道只包含亮度信息,与其他信息无关;a通道和b通道只含有颜色信息,与其他信息无关的特点,通过提取颜色通道a和b来做K均值聚类得到的标记图像渗出物区域饱满,有相当高的检出率。同时通过对比度增强,使得渗出物区域的边缘在颜色通道中更加清晰,在做K均值聚类的时候能够保证获得清晰的边缘。

通过对比图自上而下的观察,可以清晰的看到渗出物区域的逐渐变亮,这说明渗出物的检出率在逐渐增强,表示相应算法的敏感度在逐渐变大,算法的性能变得越来越好。同时基于阈值分割的算法和改进算法保持了相对清晰的边缘,而基于形态学分割的算法由于渗出物区域通过形态学重建获得,会造成渗出物边缘相对模糊。从以上实验结果中也可以看出,本文所提出的改进算法对渗出物检测的准确度较高,同时保留细节信息较多。由于渗出物的面积、边缘清晰程度和位置是判断病变进程的重要指标,因此,可认为该结果对实现渗出物的自动检测具有一定的意义。

5.3 性能比较

表 5-1 最常见的四个基本评价参数

	专家认为患病	专家认为没有患病
算法测试结果为有	真阳性(TP)	假阳性(FP)
算法测试结果为没有	假阴性(FN)	真阴性(TN)

具体解释为:对于眼科专家手工分割为病变的区域(或图像),根据算法给出结果,如果结果相同称为真阳,反之称为假阴;同理,对于眼科专家手工分割为正常的区域(或图像),根据算法结果,如果结果一致称为真阴,反之称为假阳。具体定义见表 5-1。

同时在四个基本参数的基础之上又定义了敏感性(Sensitivity, SE)、特异性(Specificity, SP)、预测率(Positive predictive value, PPV)、准确率(Accuracy, AC)等参数

$$SE = \frac{TP}{TP + FN} \quad (5-1)$$

$$SP = \frac{TN}{FP + TN} \quad (5-2)$$

$$PPV = \frac{TP}{TP + FP} \quad (5-3)$$

$$AC = \frac{TP + TN}{TP + TN + FP + FN} \quad (5-4)$$

一般而言敏感性和特异性的单调性是相反的,敏感性越高,则特异性就越低;敏感性越低,

特异性就越高。

表 5-2 显示渗出物检测算法对 DIARETDB1 图像数据库处理结果的平均指标:

Method	敏感性	特异性	预测率	准确率
基于阈值分割算法	82.14%	98.68%	84.23%	89.13%
基于形态学算法	83.21%	97.56%	87.15%	90.56%
原始 K 均值聚类算法	84.74%	99.62%	——	99.57%
改进后 K 均值聚类算法	87.57%	96.78%	89.76%	91.32%

表 5-2 渗出物检测方法平均指标

表 5-2 的平均数据对比看出, 本文提及的各种算法, 各项参数都能到达 80% 以上, 英国糖尿病协会建议糖尿病视网膜病变检测系统的病灶检测敏感性要高于 80%^[28], 因此本文算法对于渗出物检测具有一定的参考价值。同时可以发现改进后的 K 均值聚类算法较原始算法的敏感性要高, 但特异性指标始终高于 95%, 而敏感性作为评价渗出物检测算法的重要指标, 说明这些改进措施具有一定的实际效果。

5.4 本章小结

本章首先将本文算法获得的渗出物检测结果与 DIARETDB1 自带专家的手动分割结果进行对比, 根据渗出物的面积、位置以及边缘清晰程度等方面对其性能进行探讨。然后, 进一步利用敏感性、特异性等数值指标对本文算法进行定量评估, 分析其性能的改进程度, 发现改进算法相对于其他两种算法有相对较好的结果, 继承了其它两种算法的优点, 在渗出物自动检测方面具有一定的意义。

第六章 结论

6.1 总结

糖尿病视网膜病变是成年人最主要的致盲原因，而渗出物则是其早期重要的标志之一，因此它也是病变分期和诊断的重要依据。基于数字眼底图像的渗出物检测技术能有效地改善当前的医疗环境，从而有助于开展广泛的眼科普查，同时还能节省患者的诊断成本和治疗费用。

目前渗出物自动检测技术可以分为三大类：基于阈值分割的算法，基于形态学的算法，基于机器学习的算法。主要是基于颜色、灰度以及对比度等图像质量上的特征，选择合适的方法来进行识别。

本文首先介绍了两种眼底图像渗出物检测的算法，一种是基于阈值分割的算法，另一种是基于形态学分割的算法。基于阈值分割的算法的渗出物区域边缘清晰，但渗出物检出率不高，不够饱满。基于形态学分割的算法有很高的运算效率，耗时短等特点，同时该算法检测的渗出物区域的检出率高，相对比较饱满，但渗出物边缘不够清晰。这两种算法都只是改善图像质量，并没有对视网膜眼底图像内容做深度挖掘，因此都部分或完全忽视了棉绒斑、黄斑反射等干扰对渗出物检测的影响。

基于前两种算法，改进了 CIELab 和 K 均值聚类相结合的算法，属于基于机器学习的算法。在眼底图像预处理阶段，利用 HSI 色彩空间亮度通道 I 的特性，解决了视网膜图像中常见的亮度不均衡对比度偏低的问题；在 K 均值聚类阶段，依据渗出物的颜色特性，对 CIELab 色彩空间的通道 a 和 b 进行 K 均值聚类得到渗出物候选区域；在视盘检测阶段，利用视盘由明亮的斑点组成这一特点，首先计算图像中每一列的局部最大值，接着确定所有局部最大值的像素点坐标，如果不止一个像素点，那么就取中值代替，并以此点为圆心创建视盘掩膜。与前两种算法的实验结果的对比，说明改进方法在渗出物的检测效果上具有优势。

改进算法在于将 CIELab 色彩空间和 K 均值聚类算法结合起来，充分利用了渗出物在眼底图像中的特征，从而提高了渗出物的检测结果。当然改进算法也存在不足的地方，改进算法依赖于其它眼底图像结构比如视盘的分割，因此视盘的分割的好坏对渗出物最终的分割结果还是会产生一定的影响。

本课题研究横跨信息学、医学等多个领域，涉及数字图像处理、MATLAB 应用以及视网膜结构分析等多项研究内容，对提高医学图像处理水平和临床诊断水平有较大的意义。

6.2 下一步工作

虽然本文提出的基于 CIELab 色彩空间结合 K 均值聚类的改进算法，有较好的检测效果，但由于视网膜渗出物检测领域的内容相当宽泛，加上研究者的学识所限，仍有许多研究要点有待探究和改进。本文的下一步工作主要从以下几点着手：

(1) 目前渗出物的自动检测算法都部分忽视或完全忽视了与渗出物相似的其它干扰因素的影响。如果需要区分渗出物与与渗出物相似的其它干扰因素，必须使用监督类的机器学习算法。因此可以在材料充足的情况下，设计监督类的机器学习算法。

(2) 挖掘渗出物的其他特点，结合渗出物的已知特点，然后设计算法充分利用渗出物的特征，也可以减少与渗出物相似的其它干扰因素的影响。

参考文献

- [1] 陈向. 糖尿病视网膜病变图像的渗出物自动检测算法研究[D]. 哈尔滨工业大学, 2012.
- [2] 高玮玮, 沈建新, 王玉亮. RBF 神经网络和阈值分割实现视网膜硬性渗出自动检测[J]. 中国图象图形学报, 2013, 18(007): 859-865.
- [3] 周云燕, 杨坤涛, 黄鹰. 基于最小类内离散度的改进 Otsu 分割方法的研究[J]. 华中科技大学学报: 自然科学版, 2007, 35(2): 101-103.
- [4] 林蔚. 基于 K 近邻图区域合并的视网膜硬性渗出自动检测研究 [D][D]. 上海: 上海交通大学生物医学工程系, 2008.
- [5] 潘燕红, 潘林. 基于 SVM 的眼底图像硬性渗出检测[J]. 计算机与现代化, 2014 (4): 33-37.
- [6] 赵晓芳, 林土胜, 李碧. 视网膜图像中视盘的快速自动定位方法[J]. 华南理工大学学报: 自然科学版, 2011, 2: 012-012.
- [7] 高玮玮, 沈建新, 王玉亮. 基于数学形态学的快速糖尿病视网膜病变自动检测方法[J]. 光谱学与光谱分析, 2012, 32(3): 760-764.
- [8] 赖小波, 刘华山. 融合重建滤波器和暗特征的渗出物检测算法[J]. 光电子. 激光, 2013, 6: 035.
- [9] 郑绍华, 陈健, 潘林, 等. 糖尿病性视网膜病变图像黄斑水肿等级自动分析方法[J]. 中国生物医学工程学报, 2014, 31(6): 687-695.
- [10] Youssef D, Solouma N H. Accurate detection of blood vessels improves the detection of exudates in color fundus images[J]. Computer methods and programs in biomedicine, 2012, 108(3): 1052-1061.
- [11] Reza A W, Eswaran C, Dimyati K. Diagnosis of diabetic retinopathy: automatic extraction of optic disc and exudates from retinal images using marker-controlled watershed transformation[J]. Journal of medical systems, 2011, 35(6): 1491-1501.
- [12] Sinthanayothin C, Boyce J F, Cook H L, et al. Automated localisation of the optic disc, fovea, and retinal blood vessels from digital colour fundus images[J]. British Journal of Ophthalmology, 1999, 83(8): 902-910.
- [13] Sinthanayothin C, Boyce J F, Williamson T H, et al. Automated detection of diabetic retinopathy on digital fundus images[J]. Diabetic medicine, 2002, 19(2): 105-112.
- [14] Rajput G G, Patil P N. Detection and classification of exudates using k-means clustering in color retinal images[C]//Signal and Image Processing (ICSIP), 2014 Fifth International Conference on. IEEE, 2014: 126-130.
- [15] Sopharak A, Uyyanonvara B. Automatic exudates detection from diabetic retinopathy retinal image using fuzzy c-means and morphological methods[C]//Proceedings of the third IASTED international conference Advances in Computer Science and Technology, Thailand. 2007: 359-364.
- [16] Gardner G G, Keating D, Williamson T H, et al. Automatic detection of diabetic retinopathy using an artificial neural network: a screening tool[J]. British journal of Ophthalmology, 1996, 80(11): 940-944.

- [17] Osareh A, Mirmehdi M, Thomas B, et al. Comparative exudate classification using support vector machines and neural networks[M]//Medical Image Computing and Computer-Assisted Intervention—MICCAI 2002. Springer Berlin Heidelberg, 2002: 413-420.
- [18] Osareh A, Mirmehdi M, Thomas B, et al. Automated identification of diabetic retinal exudates in digital colour images[J]. British Journal of Ophthalmology, 2003, 87(10): 1220-1223.
- [19] 方兴. 眼科常识[J]. 中国眼镜科技杂志, 2002(3):26.
- [20] 周琳. 眼底图像中血管分割技术研究[D]. 南京: 南京航空航天大学, 2011.
- [21] 李居朋. 眼底图像处理与分析中一些关键问题的研究[D]. 北京: 北京交通大学, 2009.
- [22] 冈萨雷斯等. 数字图像处理(MATLAB 版)[M]. 阮秋琦等译. 北京: 电子工业出版社, 2005.
- [23] 赵丹. SVM 核函数与选择算法[J]. 数字技术与应用, 2014 (9): 226-226.
- [24] Pourreza H. Localization of hard exudates in retinal fundus image by mathematical morphology operations[C]//Computer and Knowledge Engineering (ICCKE), 2012 2nd International eConference on. IEEE, 2012: 185-189.
- [25] Gaikwad N N, Mane V M. Detection of Hard Exudates using K-Mean Clustering for Screening of Diabetic Retinopathy[J].
- [26] 袁 方, 周志勇, 宋 鑫. 初始聚类中心优化的 k-means 算法[J]. 计算机工程, 2007, 33(03): 65-66.
- [27] Kauppi T, Kalesnykiene V, Ka-marainen J K, et al. DIARETDB1-STANDARD DIABETIC RETINOPATHY DATABASE[J].<http://www2.lut.fi/project/imageret/diaret/db1/>, 2007-06-19.
- [28] British Academic Association. Retinal Photography Screening for Diabetic Eye Disease[R]. London: British Academic Association, 1997.

谢辞

首先,要感谢我的导师杨宇红老师,在为期半年的毕业设计过程中给予了我许多指导与鼓励。特别是在我对课题难以开始的时候,不厌其烦地为我提供了方向上的宝贵的建议,让我的工作能够顺利的开展下去。在论文撰写过程中,细心帮助我修改了多次。她严谨的治学风格和渊博的专业知识令人敬佩。

其次,要感谢网络上无私共享部分源代码的研究者们,尽管之间并没有直接进行过交流,但从他们所书写的源代码中我学到了很多 matlab 处理方面的知识,学会如何利用 matlab 来处理图像问题。同时了解到渗出物检测的详细处理步骤,让我少走了许多弯路。

感谢与我共同在毕设上奋战的电子系同学们,在整个毕设过程中,他们与我分享了这一段难忘的时光,也为我提供了很多帮助。

最后,感谢所有电院的老师们,对我四年的培养使我掌握了扎实的理论功底,让我在本次毕业设计课题研究中能够学以致用,顺利完成课题工作。

AUTOMATIC EXUDATE DETECTION IN COLOR RETINAL IMAGE

Diabetes is becoming more popular all over the world. And diabetic retinopathy (DR) is a serious complication caused by diabetes, leading to vision loss even blindness for adults in the first place. The pathological basis is abnormal retinal microcirculation, causing structural and functional microcirculation disorders. It shows that the capillary wall pericytes gradually disappear, causing precapillary arteriovenous shunt. While endothelial cell proliferation and basement membrane thickening, the ability of automatically adjustment becomes less, finally leading to capillary ischemia, hypoxia and neovascularization on the retinal fundus. Micro aneurysm (Ma) is one of the early features of diabetic retinopathy, which is caused by the expansion of capillaries. The performance of the red or dark red circular or oval spots on the retinal fundus. Capillary hemangioma rupture can lead to retinal bleeding, sometimes called hemorrhages, generally occurs in the beginning. Bright yellow lesions on the retinal fundus are hard exudates (Hes), which is one of the characteristic findings of diabetic retinopathy. What increased vascular permeability, resulting in class from serum lipid exudation, stacked to form, mainly ranging from the edge is called HEs. It is more clearly speckled. Hard exudates may not be regularly distributed to the eyes, but the most common posterior pole, more than clustered stacking, some merging into pieces, some arranged in a ring. Further damage is lint bright white spots, also called soft exudates (SEs), mainly located in the bifurcation of the arteries. But it is not the specific changes of diabetic retinopathy, hypertensive patients retinal fundus also existed commonly.

Studies have shown that, through periodic retinal examination, nearly 90% patients could have been avoided visual impairment and even blindness. However, the artificial retinal fundus image screening takes a lot of time and effort, but with low accuracy and repeatability. If we can screen retinal fundus image automatically, it can prevent blindness and visual impairment caused by diabetic retinopathy effectively. Detection of exudates on the retinal fundus is a key step in a computer-aided diagnostic system, promoting retinal fundus detection and reducing costs of retinal fundus screening.

Automatic exudates detection algorithms can be divided into three categories: threshold-based segmentation algorithm, morphology-based segmentation algorithm and based on machine learning algorithm. The algorithms are based on color, grayscale and contrast, and then select the appropriate method to identify exudates.

This paper have implemented two basic algorithm and an improved algorithm, followed to compare its performance. The first algorithm: we have used morphological and thresholding methods to segment the candidate exudates regions on the retinal fundus. The second algorithm: firstly, we have used the ball filter to remove the blood vessels, and then the column filter has conducted to mark exudates regions. Secondly, have used Top-hat Transform to obtain dark features. Finally, dark features has subtracted from the exudates regions.

Based on the first two algorithms, we have also raised an improved algorithm based on CIELab and K-means clustering, belonging to machine learning algorithms.

At first, the red, green, and blue color space is converted into hue, saturation and intensity color space. Intensity is one of Primary classification features to identify exudates. The HSI space is preferred because it allows to be separated into one intensity components and the two color components. Retinal fundus images may be noisy, sometimes with non-uniform illumination due to various reasons, leading the contrast of the images insufficiently. Therefore, using limited adaptive histogram equalization contrast (CLAHE) for contrast enhancement is a great way, making it possible to distinguish the visual appearance of exudates. But with this enhancement, image noise has also been enhanced, which is not required. Accordingly, Hence Median filter is applied prior to CLAHE. After preprocessing the HSI image is converted to RGB color space for further processing.

Secondly, hard exudates are the bright lesions in the retinal fundus images with distinct boundaries. Here we use the CIELab color space. Firstly, we convert the enhanced RGB image to CIELab color space. The chromaticity layer of a and b are extracted from CIELab color space for color separation. This matrix containing only color information is used for k-means clustering algorithm. The traditional k-means clustering is very sensitive to the initial cluster centers. Generally different initial cluster centers corresponding to different clustering results. In this case, using Euclidean distance as the similarity measure of k-means clustering algorithm. Generally, it is more representative to select the farthest k data than randomly selected data. Because the actual data set is usually the presence of noise data. If we just select k farthest data points simply, sometimes noise data points are taken with unsatisfactory clustering effect. It is generally believed that a small amount of noise data in the low density region is always dispersed. However, a large concentration of data in high-density areas is always valid, Therefore, in order to avoid taking the noise points, you can choose k farthest data points from the high-density area as the initial cluster centers. In order to calculate the density of location, we first define a density parameter A: its radius contains constant N data points. Density parameter greater, indicating lower density data in your area. In contrast, the density parameter is smaller, the higher the density of data in your area. So it can calculate the density parameter of each data, and then obtain a high density point set.

Finally, as the optical disk is made up of a group of bright spots, it is not suitable to use loops and locate the largest value. This would only point to one spot and most likely to be on the side of the optical disk. The mask required to cover the optical disk would be inefficient as it would be much larger and covers more details. Mask creation is used in the detection of blood vessels, exudates and microaneurysms. Grayscale image instead of the green channel is used as it is more efficient in the detection. The above lines would first find the max value for each of the columns of the image before locating the largest value. The coordinates (row and column) of all brightest points are then determined and the median is taken if there is more than one point. After locating the optical disk, a mask needs to be created. A simple square mask created using loops would be easy but this would result in error when the optical disk is close to the border of the image. The above lines are used instead to generate the circular mask. The function “meshgrid” is to generate x and y matrices while the next line that creates the mask is the equation for drawing circle, m and n are the coordinates (row and column) and R as the Radius.

$$R^2 = (x - m)^2 + (y - n)^2 \quad (1-1)$$

Then, the optic disk is subtracted from the main cluster image.

The first one is based on threshold segmentation algorithm. The exudates regions have sharp edges, but the detection rate of exudates is not high. The second one is based on morphological segmentation algorithm. It takes less time to detect exudates with high computational efficiency. While the detection rate of exudate region is relatively full, but with the fuzzy edge. Both two algorithms just improve image quality, which don't excavate the content of the retinal fundus images. So they ignore the lint spots, macular reflection interference on exudate detection partially or completely.

The improved algorithm uses not only take advantage of color information and luminance information, but also the use of sharp edge features extracted from exudates. L channel from CIELab color space contains only luminance information, without other information; a channel and b channel containing only color information. The chromaticity layer of a and b are extracted from CIELab color space for color separation. This matrix containing only color information is used for k-means clustering algorithm. It can detect exudates effectively with a very high detection rate of exudates. Due to contrast enhancement at the same time, so the edges of exudates regions are more sharp and clearly in the color channels. In theory, it is possible to save the edge information. From the actual experimental results, we can see that the automatic exudates detection algorithm with a high accuracy, while preserving more details in exudates regions and edges. So the improved algorithm performs well. Since the area of exudate, sharp edges are an important indicator of the extent and location of the disease process is determined, therefore, that the result may have some significance for the automatic detection of exudate.

The innovation is that we will combine CIELab color space and K-means clustering algorithm to take full advantage of the features in the fundus exudation image, thereby improving the detection result of exudate. Of course, there are deficiencies of improved algorithms. Improved algorithms rely on other structures such as optic fundus image segmentation, thus dividing the quality of the disc will have some impact to the final segmentation result exudate.

This research crosses multiple fields, from information science to and medicine, relating to digital image processing, MATLAB applications as well as a number of research retina structure analysis. It has a great significance to improve the level of medical image processing and clinical diagnosis.